МИСИС УНИВЕРСИТЕТ

Кафедра инженерной кибернетики

Алгоритм Learned DBP для компенсации искажений в волоконно-оптических линиях связи

Выполнил: студент группы БПМ-22-ПО-1,
Голубев Иван Максимович

Научный руководитель: старший преподаватель,
Семёнов Валерий Васильевич

Дата проведения: 04.03.2026

Актуальность

$$C = M \cdot B \cdot \log_2(1 + S/N)$$

Основная проблема

- Увеличение пропускной способности волоконно-оптической линии связи **C**, определяемой согласно теореме Шеннона-Хартли. Так как увеличение полосы пропускания **B**, числа степеней свободы **M** и мощности сигнала **S** ограничено технологическими возможностями – уменьшаем влияние шума **N**.

Задача

- Научиться переводить искажения сигнала из разряда неотличимых от шума детерминированных искажений в разряд компенсированных – увеличиваем отношение **S/N**.
- В протяженных волокнах (>100 км) искажения сигнала описываются нелинейным уравнением Шредингера. Однако аналитического решения оно не имеет, а наиболее точный численный подход, метод расщепления Фурье (SSFM), требует слишком много вычислительных ресурсов.

Возможное решение

Интерпретация SSFM как нейронной сети PINN (аналогичная структура) – за счёт чего можно выполнить сокращение и оптимизацию параметров.

Основные определения

Искажение сигнала – отклонение формы принятого сигнала от переданного, вызванное совместным действием хроматической дисперсии (линейные искажения) и эффекта Керра (нелинейные искажения) при распространении по оптическому волокну

Цифровое обратное распространение (**DBP**) – подход к компенсации искажений, основанный на решении нелинейного уравнения Шредингера

Метод расщепления Фурье (SSFM) – численный метод решения нелинейного уравнения Шредингера, при котором распространение сигнала на малом участке разбивается на два независимых этапа: линейный (дисперсия) и нелинейный (эффект Керра)

Физически-информированная нейронная сеть (PINN) – класс моделей, структура которых отражает физические уравнения, что сокращает пространство поиска и повышает их интерпретируемость

Обученное цифровое обратное распространение (**Learned DBP**) – гибридный алгоритм цифровой компенсации искажений, который представляет из себя DBP, решение уравнения Шредингера выполняется PINN, основанной на SSFM

Предметная область

Границы предметной области

1) Когерентная одномодовая волоконно-оптическая линия связи (SSMF) длиной более 500 км
2) Цифровая компенсация на приемной стороне (RX-DSP)
3) Физически-информированные нейросети (PINN), интегрированные в структуру DBP

Объект исследования

Процесс искажения сигналов при распространении в протяженной одномодовой линии связи

Предмет исследования

Алгоритм обученного цифрового обратного распространения (Learned DBP), аппроксимирующий схему расщепления Фурье с целью повышения вычислительной эффективности компенсации искажений.

Содержательная постановка задачи

Цель исследования

Разработка и построение архитектуры физически-информированной нейросети в алгоритме Learned DBP на основе метода расщепления Фурье и обучение ее параметров при помощи минимизации квадрата ошибки между восстановленным и переданным сигналами.

Задачи НИР-7

- Проанализировать предметную область
- Получить и проанализировать датасет
- Выполнить обзор основных методов цифровой компенсации искажений
- Разработать формальную постановку задачи

Основной результат НИР-7

Структурированный отчет и датасет, определены входные и выходные данные

Математическая постановка задачи

Вектор комплексных огибающих сигнала, где z – координата вдоль волокна длины L, t – время:

$$\mathbf{A}(z,t) = (A_x(z,t), A_y(z,t))^T \in \mathbb{C}^2$$

Нелинейное уравнение Шрёдингера, где i – мнимая единица:

$$\frac{\partial \mathbf{A}}{\partial z} = -\frac{\alpha}{2}\mathbf{A} - i\frac{\beta_2}{2}\frac{\partial^2 \mathbf{A}}{\partial t^2} + i\frac{8}{9}\gamma||\mathbf{A}||^2\mathbf{A} \text{ и } ||\mathbf{A}||^2 = |A_x|^2 + |A_y|^2$$

Характеристики оптоволокна:

α – коэффициент затухания (уменьшение мощности сигнала) [Дб / км]

β_2 – коэффициент хроматической дисперсии (расплывание импульсов во времени) [пс^2 / км]

γ – нелинейный коэффициент (фазовая самомодуляция) [рад / (Ват · км)]

Математическая постановка задачи

Переданный сигнал:

$$\mathbf{x}(t) = \mathbf{A}(z=0,t)$$

Полученный сигнал:

$$\mathbf{y}(t) = \mathbf{A}(z=L,t)$$

Нелинейный оператор Шредингера:

$$\mathscr{H} = \left(-\frac{\alpha}{2} - i\frac{\beta_2}{2}\frac{\partial^2}{\partial t^2}\right) + \left(i\frac{8}{9}\gamma||\cdot||^2\right),$$

$\mathscr{H} : \mathscr{F} \to \mathscr{F}$, где $\mathscr{F}$ – пространство вектор-функций вида $(z,t) \mapsto \mathbf{A}(z,t)$

Оператор эволюции сигнала:

$$\mathbf{y} = e^{L\mathscr{H}}\mathbf{x} = \sum_{n=0}^{\infty}\frac{L^n}{n!}\mathscr{H}^n\mathbf{x}$$

Метод компенсации DBP:

$$\mathbf{x} = e^{-L\mathscr{H}}\mathbf{y}$$

Математическая постановка задачи

Аппроксимация оператора эволюции сигнала осуществляется нейронной сетью вида:

$$\mathbf{f}_\theta : \mathbb{C}^2 \to \mathbb{C}^2,$$

где $\boldsymbol{\theta}$ – вектор параметров модели, $\hat{\mathbf{x}} = \mathbf{f}_\theta(\mathbf{y})$ – восстановленный сигнал, ее архитектура в **Приложении 1**. Обучающая выборка (N пар из переданного и полученного сигналов):

$$\{(\mathbf{x}_1, \mathbf{y}_1), \ldots, (\mathbf{x}_N, \mathbf{y}_N)\}$$

Задача обучения модели Learned DBP:

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} \frac{1}{N} \sum_{n=1}^{N} ||\mathbf{x}_n - \hat{\mathbf{x}}_n||^2$$

Исходные данные

Источник:
Moscow Optic Algorithm Laboratory, **Huawei**

Объем:
259.072 пары комплексных чисел: первое это комплексная огибающая сигнала на выходе из передатчика, второе это комплексная огибающая сигнала на входе в приемник

Параметры модели волоконно-оптической линии связи:

- Источник сигнала – лазер с длиной волны **1550** нм и излучаемой мощностью >**10** дБм
- Протяжённость линии: **640** км
- Формат модуляции: **16QAM** (4 бита на символ) с кодированием Грея (Gray mapping)
- Коэффициент затухания (α): **0.2** дБ/км
- Коэффициент хроматической дисперсии (β_2): **-21.683** пс^2/км
- Нелинейный коэффициент Керра (γ): **1.3** рад/(Вт·км)

Инструментарий

Методы моделирования и анализов результатов

1. Математическое и алгоритмическое моделирование Learned DBP модели
2. Сравнительный вычислительный анализ моделей компенсации нелинейных искажений

Методы глубокого обучения

1. Physics-Informed Neural Networks (PINN) – модель Learned DBP, основанная на SSFM
2. Оптимизатор Adam – обучение параметров нейронной сети

Технологический стек

1. Язык программирования: Python
2. Используемые библиотеки: Tensorflow, NumPy, Pandas

Выводы

- Проведен аналитический обзор научных источников в области алгоритмов цифровой компенсации нелинейных искажений в волоконно-оптических линиях связи
- Получен и проанализирован датасет от лаборатории Huawei
- Сформулирована математическая задача КНИР: оптимизация лосс-функции на основе среднеквадратичной ошибки восстановления исходного сигнала
- Разработана первая версия архитектуры PINN модели

МИСИС
УНИВЕРСИТЕТ

Спасибо
за внимание!

Приложение 1 (архитектура PINN)

Архитектура PINN на данный момент выглядит следующим образом: **K** слоёв, каждый из которых соответствует шагу SSFM и аппроксимирует оператор эволюции на отрезке длины $\mathbf{h_k}$ вида $e^{-h_k\mathscr{H}}$; $\mathbf{u_k}$ – на входе в блок, $\mathbf{u_{k+1}}$ – сигнал на выходе из блока.

1. Линейный блок (FIR-фильтр с коэффициентами $\mathbf{a}_k[m] \in \mathbb{C}^2$, где $m = -M, \ldots, M$):

$$\mathscr{D}_k[\mathbf{u}_{k+1}] = \sum_{m=-M}^{M} \mathbf{a}_k[m] \odot \mathbf{u}_{k+1}(t - m\Delta t)$$

2. Нелинейная функция активация (повторяет нелинейный шаг SSFM):

$$\boldsymbol{\sigma}_k(\mathbf{u}_{k+1}) = \mathbf{u}_{k+1} \cdot e^{i\gamma h_k \|\mathbf{u}_{k+1}\|^2}$$

Итоговый вид модели PINN как композиции линейного и нелинейного шагов:

$$\mathbf{f}_\theta(\mathbf{y}) = \boldsymbol{\sigma}_1(\mathscr{D}_1[\ldots[\boldsymbol{\sigma}_K(\mathscr{D}_K[\mathbf{y}])]\ldots])$$

Приложение 2 (сравнительный анализ)

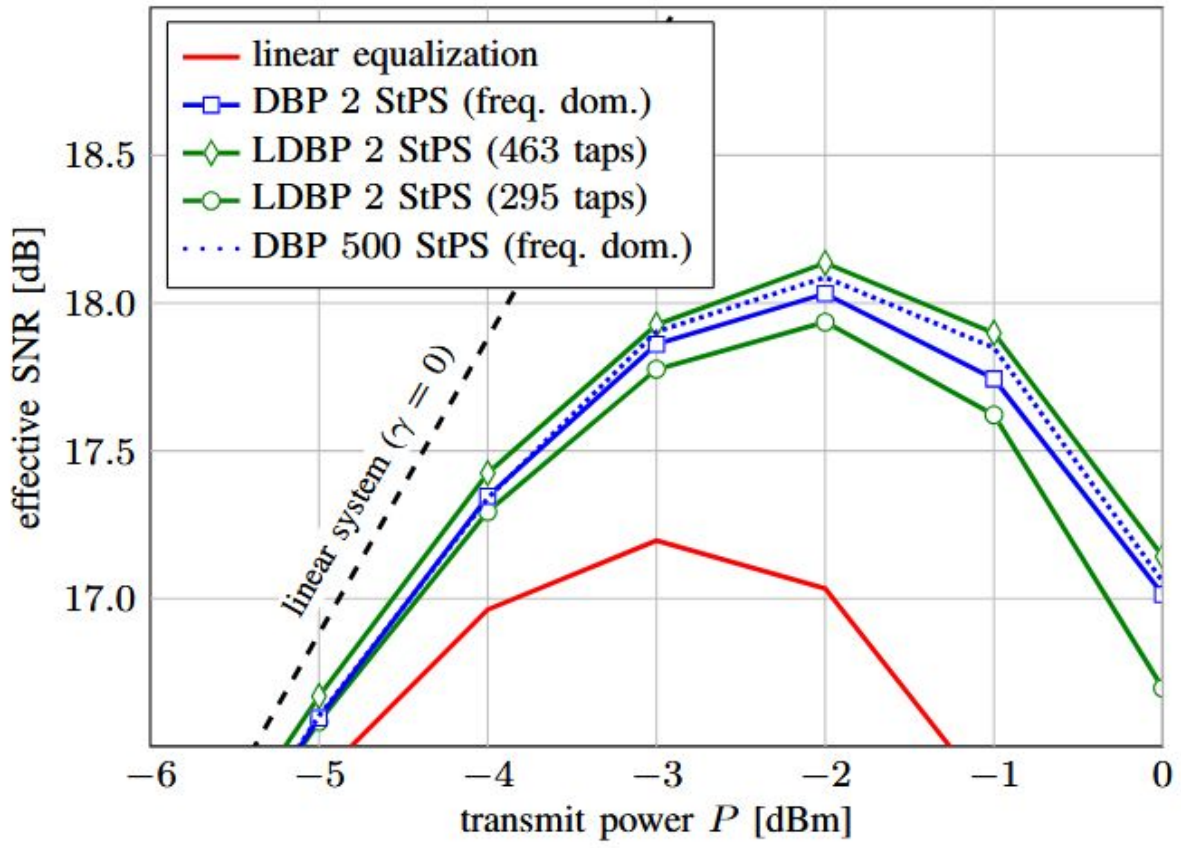

Physics-Based Deep Learning for Fiber-Optic Communication Systems. Christian Häger, Henry D. Pfister. 2020

Согласно графику, выигрыш в эффективном SNR (отношению сигнала к шуму) при использовании Learned DBP такой же, как и при использовании полноценной связки DBP с SSFM. Однако выигрыш в количестве операций следующий:

- DBP выполняет **500** операций (вычисление DFT + умножение матриц)
- Learned DBP выполняет **2** операции (имея два линейных FIR-фильтра с 463 отводами)

Уменьшение операций в **250** раз!